Extraction d'information dans les annuaires de la ville de Strasbourg (1873-1953)

Fortuné Wladimir TOSSA

Laboratoire LITIS

July 2, 2026

Plan

1. **Processus d'extraction**
2. **Limites**
3. **Performances**
4. **Extractions**

Processus d'extraction

Architecture et matériel



- Appels API ;
- Limites de tokens ;
- Temps de traitement : **7min/fichier**



- Installé sur un demi-serveur H100 du LITIS ;
- 64 Gb VRAM ;
- jusqu'à 4 requêtes en parallèle ;
- Temps de traitement : **1min 30s/fichier**.

Processus d'extraction



*Allgemeine Elsässische Bankgesellschaft in Strassburg i. Els. Société générale alsacienne de Banque, Actiengesellschaft. Vorstand: Henri Kling in Strassburg und Alfred Kossmann in Frankfurt a. M. Proc.: Florent Wernert. Betriebsdirector Fernand Herrenschmidt, Münsterg. 8, Telephon 86.

⇓ Texte brut via OCR ⇓

```
*Allgemeine Elsässische Bankgesellschaft in Strassburg i.  Els.  Société générale alsacienne de
Banque, Actiengesellschaft.  Vorstand:  Henri Kling in Strassburg und Alfred Kossmann in Frankfurt a.
M. Proc.:Florent Wernert.  Betriebsdirector Fernand Herrenschmidt, Münsterg.  8, Telephon 86.
```

⇓ Données structurées via LLM (Qwen 3.6) ⇓

NOM	PRÉNOM	PROFESSION	COMPLÉMENT DE PROFESSION	NOM DE VOIE	NUMÉRO DE VOIE
Kling	Henri	Vorstand	*Allgemeine Elsässische Bankgesellschaft...	*	*
Kossmann	Alfred	Vorstand	*Allgemeine Elsässische Bankgesellschaft...	*	*
Wernert	Florent	Proc.	*Allgemeine Elsässische Bankgesellschaft...	*	*
Herrenschmidt	Fernand	Betriebsdirector	*Allgemeine Elsässische Bankgesellschaft...	Münsterg.	8

*Note : Les colonnes FAUBOURG, PROPRIÉTAIRE, NOM DE JEUNE FILLE, SITUATION et ADRESSE PROFESSIONNELLE sont vides (*) pour ces entrées.

Difficultés dues aux données

Bruits textuels

1874



Imbach, geb. Göpp, Emilie, Wwe., Weissethurmstrasse 58.
Imbér Carl, Eisenb.-Beamter, Thomannsgasse 9.
Imbs Adolph, Maler, Roth Quartier 70.
— Jacob, Drechsler, Krebsgasse 9.
— Ignatz, Rentier, Neufeldweg 11.
— Wilhelm, Zimmermann, Steinwallstr. 17.
Imhof Alois, Weber, Neuhof 255.
— Joseph, Weber, Neuhof 225.
— Lorenz, Taglöhner, Hechtengasse 3.
— Louis Jacob, Kellner, Hechtengasse 3.
Imler Anton, Schuhmacher, Bruderhofsgasse 3.
— Carl, Schuhmacher, Quergasse 11.

1882



Allgayer, Anton, Tagner, Bruckhof 13.
— Johann, Tagner, Neudorf Altschulg. 51.
*— Wilhelm, Inh.: Wilhelm Allgayer, Wurstler, Fischerstad. 5.
— Xaver, Zimmermann, Rupr. Pfütz eng. 39.
***Allgemeine Elsässische Bank - Gesellsch.,** (Société générale alsacien de Banque) Vorstand: Alfred Herrenschmidt, Vorsitzender, Joachim Bruel, delegirter Verwalter, Münstergasse 8.
***Allgemeine Gesch. - Agentur Els. - Lothr.** Constantin Bloch, Kaufm., alt. Fischmarkt 23.
***Allinger,** L., Inh.: Leonhard Allinger, Pianoforte-Fabkt., Schiffleutstad. 31.
— Leonh., Rentn., Schiffleutstad. 31.

TEXTE OCR 1882

```
Allgayer, Anton, Tagner, Bruckhof 13.
— Johann, Tagner, Neudorf Altschulg. 51. • — Wilhelm, Inh.: Wilhelm Allgayer,
Wurstler, Fischerstad. 5.
— Xaver, Zimmermann, Rupr. Pfütz eng. 39. •Allgemeine Elsässische Bank -
Gesellsch., (Société générale alsacien de Banque) Vor stand: Alfred
Herrenschmidt, Vorsitzender, Joachim Bruel, delegirter Verwalter, Münster gasse
8. "Allgemeine Gesch. - Agentur Els. - Lothr. Constantin Bloch, Kaufm., alt.
Fischmarkt 23. *Allinger, L., Inb.: Leonhard Allinger, Pianoforte-Fabkt.,
Schiffleutstad. 31.
— Leonh., Rentn., Schiffleutstad. 31.
```

Performances

Performances 1/2

- Tests effectués sur un ensemble de 509 entrées représentatives extraites manuellement ;
- les extractions du modèle sont comparées avec les extractions manuelles ;
- taux de réussite de **98%**

Performances 2/2

Texte OCR 1882

```
Allgayer, Anton, Tagner, Bruckhof 13.
— Johann, Tagner, Neudorf Altschulg. 51. • — Wilhelm, Inh.: Wilhelm Allgayer,
Wurstler, Fischerstad. 5.
— Xaver, Zimmermann, Rupr. Pfütz eng. 39. •Allgemeine Elsässische Bank -
Gesellsch., (Société générale alsacien de Banque) Vor stand: Alfred
Herrenschmidt, Vorsitzender, Joachim Bruel, delegirter Verwalter, Münster gasse
8. "Allgemeine Gesch. - Agentur Els. - Lothr. Constantin Bloch, Kaufm., alt.
Fischmarkt 23. *Allinger, L., Inb.: Leonhard Allinger, Pianoforte-Fabkt.,
Schiffleutstad. 31.
— Leonh., Rentn., Schiffleutstad. 31.
```

Extraction CSV par Qwen 3.6

```
NOM,PRENOM,PROFESSION,COMPLEMENT,NOM_VOIE,NUM_VOIE,FAUBOURG
Allgayer,Anton,Tagner,*,Bruckhof,13
Allgayer,Johann,Tagner,*,Altschulg.,51,Neudorf
Allgayer,Wilhelm,Wurstler,"*Allgayer, Wilhelm",Fischerstad.,5
Allgayer,Xaver,Zimmermann,*,Pfützeng.,39,Rupr.
Herrenschmidt,Alfred,Vorsitzender,Allgemeine Elsässische Bank - Gesellsch. (Société générale  alsacien de Banque) Vorstand,Münstergasse,8
Bruel,Joachim,delegirter Verwalter,Allgemeine Elsässische Bank - Gesellsch. (Société générale  alsacien de Banque) Vorstand,Münstergasse,8
Bloch,Constantin,Kaufm.,*Allgemeine Gesch. - Agentur Els. - Lothr.,alt. Fischmarkt,23
Allinger,Leonhard,Pianoforte-Fabkt.,"*Allinger, L.",Schiffleutstad.,31
Allinger,Leonh.,Rentn.,*,Schiffleutstad.,31
```

Résultats

Validation par TEST 1 : Ordre Alphabétique

TEST 1 : Vérification de l'ordre alphabétique des noms

- Permet de contrôler la qualité de l'extraction sur la colonne NOM ;
- si l'ordre n'est pas respecté , une anomalie d'extraction est détectée ;
- si le nombre d'erreurs est supérieur au seuil (10 par défaut), l'image du fichier est repassée à l'OCR.

LIMITE : Fausse alerte fréquente sur les entrées d'entreprise (à partir de 1882).

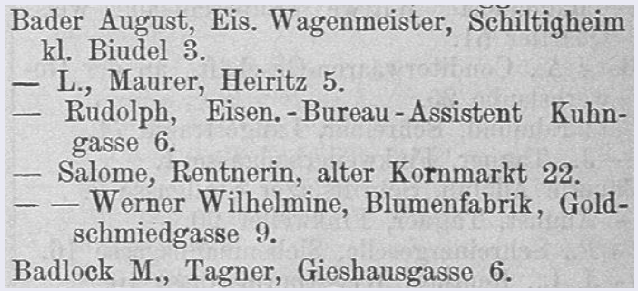
Validation par TEST 1 : Ordre Alphabétique

TEST 1 : Vérification de l'ordre alphabétique des noms

- Permet de contrôler la qualité de l'extraction sur la colonne NOM ;
- si l'ordre n'est pas respecté, ALERT_1 ajoutée à la ligne ;
- si le nombre de lignes erronées est supérieur au seuil (10 par défaut), l'image du fichier est repassée à l'OCR.

LIMITE : Fausse alerte fréquente sur les entrées d'entreprise (à partir de 1882).

Extrait de l'image source (Scan)


Bader August, Eis. Wagenmeister, Schiltigheim kl. Biudel 3.
— L., Maurer, Heiritz 5.
— Rudolph, Eisen.-Bureau-Assistent Kuhngasse 6.
— Salome, Rentnerin, alter Kornmarkt 22.
— — Werner Wilhelmine, Blumenfabrik, Goldschmiedgasse 9.
Badlock M., Tagner, Gieshausgasse 6.

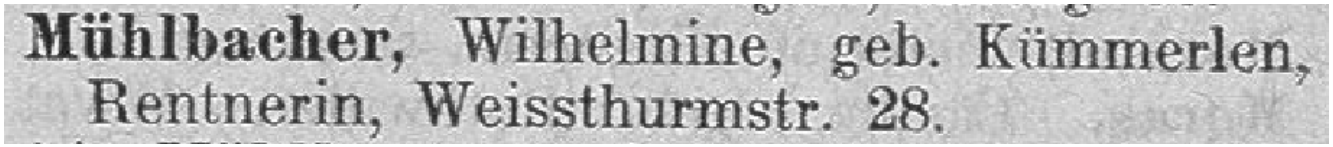
Transcription brute via OCR

```
Bader ...
-- Salome, Rentnerin, alter Kornmarkt 22.  Werner
Wilhelmine,Blumenfabrik,Gold schmiedgasse 9.
Badlock M., Tagner, Gieshausgasse 6.
```

Extraction CSV

NOM	PRÉNOM	PROF.	COMPL. PROF.	VOIE	N°	...	SIT.	TAG_1
Bader	Salome	Rentnerin	*	alter Kornmarkt	22	...	*	*
Werner	Wilhelmine	Blumenfabrik	*	Gold schmiedgasse	9	...	*	ALERT_1
Badlock	M.	Tagner	*	Gieshausgasse	6	...	*	*

Validation par TEST 2 : Similarité CSV-TEXT


Mühlbacher, Wilhelmine, geb. Kümmerlen,
Rentnerin, Weissthurmstr. 28.

⇓ Mêmes mots , ordre différent ⇓

```
Mühlbacher,Wilhelmine,Rentnerin,*,Weissthurmstr.,28,*,*,Kümmerlen,*,*
```

TEST 2 : Vérification du niveau de similitude entre la ligne de texte et le csv.

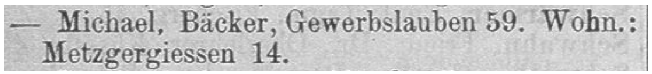
- Permet de s'assurer que toutes les données attendues sont extraites ;
- ajoutée si la ligne extraite perd de l'information ou en contient beaucoup plus que le texte original ;
- texte original ajouté dans le fichier csv pour permettre une validation.

LIMITES:

- beaucoup de fausses alertes sur les lignes d'entreprises ;
- à considérer comme des points d'attention.

Validation par TEST 2 : Exemples

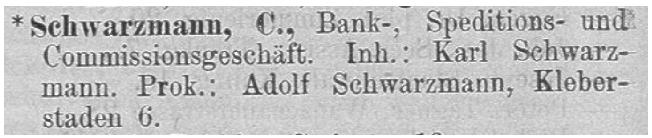
Information manquante


— Michael, Bäcker, Gewerbslauben 59. Wohn.: Metzgergiessen 14.

NOM	PRÉNOM	PROF.	COMPL. PROF.	VOIE	N°	TEST_2	TEXTE
Schwartz	Michael	Bäcker	*	Gewerbslauben	59	ALERT_2	[ci-dessous]

TEXTE : Michael, Bäcker, Gewerbslauben 59. Wohn.: Metzgergiessen 14.

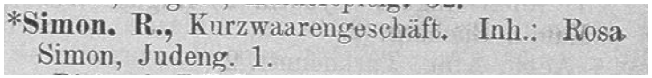
Fausse alerte


*Schwarzmann, C., Bank-, Speditions- und Commissionsgeschäft. Inh.: Karl Schwarzmann. Prok.: Adolf Schwarzmann, Kleberstaden 6.

NOM	PRÉNOM	PROF.	COMPL. PROF.	VOIE	N°	TEST_2	TEXTE
Schwarzmann	Karl	Kaufm.	*Schwarzmann, C., Bank-, Sped...	Kleberstaden	6	ALERT_2	[ci-dessous]
Schwarzmann	Adolf	Prokurist	*Schwarzmann, C., Bank-, Sped...	Kleberstaden	6	ALERT_2	[ci-dessous]

TEXTE : *Schwarzmann, C., Bank-, Speditions- und Commissionsgeschäft. Inh.: Karl Schwarzmann. Prok.: Adolf Schwarzmann, Kleberstaden 6.

Information supplémentaire


*Simon. R., Kurzwaarengeschäft. Inh.: Rosa Simon, Judeng. 1.

NOM	PRÉNOM	PROF.	COMPL. PROF.	VOIE	N°	TEST_2	TEXTE
Simon	Rosa	Kaufmann	*Simon. R., Kurzwaarengeschäft...	Judeng.	1	ALERT_2	[ci-dessous]

TEXTE : *Simon. R., Kurzwaarengeschäft. Inh.: Rosa Simon, Judeng. 1.

*Note : Les colonnes vides (FAUBOURG, PROPRIÉTAIRE, NOM DE JEUNE FILLE, SITUATION, ADRESSE PRO. et TEST_1) ont été masquées pour des raisons de place.

Validation par TEST 3 : Qualité des valeurs extraites

TEST 3 : Vérifier si **OUI/NON** la valeur correspond au champ où elle a été mise.

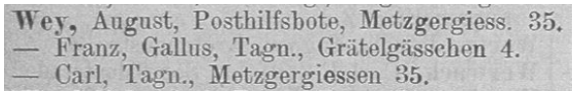
- Permet d'éliminer les confusions possibles entres les éléments d'une entrée ;
- Utilisation d'un dictionnaire de valeur par champ ;
- une valeur absente du dictionnaire est classée par un modèle de machine learning avec un score de confiance ;
- l'alerte est ajoutée en cas de rejet par le classifieur ou en cas de classification avec faible confiance ;
- la valeur et le score de classification sont ajoutés à la ligne csv.

LIMITES:

- confusions en raison des abréviations ;

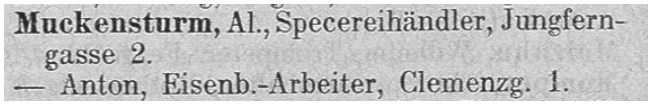
Validation par TEST 3 : Exemples

Mauvaise classification


Wey, August, Posthilfsbote, Metzgergiess. 35.
— Franz, Gallus, Tagn., Grätelgässchen 4.
— Carl, Tagn., Metzgergiessen 35.

NOM	PRÉNOM	PROF.	COMPL. PROF.	VOIE	N°	TEST_3
Wey	Franz	Tagn.	Gallus	Grätelgässchen	4	**ALERT_3** E_prof : 'Gallus' (Faux à 89.56%)

Fausse alerte en raison d'une abréviation


Muckensturm, Al., Specereihändler, Jungfern-
gasse 2.
— Anton, Eisenb.-Arbeiter, Clemenzg. 1.

NOM	PRÉNOM	PROF.	CMP. PR.	VOIE	N°	TEST_3
Muckensturm	Anton	Eisenb.-Arbeiter	*	Clemenzg.	1	**ALERT_3** E_nom_v:'Clemenzg.' (Faux à 95.24%)

*Note : Les colonnes vides (FAUBOURG, PROPRIÉTAIRE, NOM DE JEUNE FILLE, SITUATION, ADRESSE PRO. et TEST_1/TEST_2) ont été masquées pour des raisons de place.

Statistiques des alertes sur les fichiers (1873 à 1900)

1873 – 1888

- Corpus de **1099 fichiers** analysés.
- **217785** lignes analysées
- **19 fichiers** dépassent le seuil de 5 % d'alertes `ALERT_1`.

Taux globaux d'alertes :

Alerte	Nombre de lignes	Pourcentage
ALERT_1	2190	1 %
ALERT_2	5585	2,56 %
ALERT_3	5281	2,42 %

1890 – 1900

- Corpus de **1725 fichiers** analysés.
- **314774** lignes analysées
- **50 fichiers** dépassent le seuil de 5 % d'alertes `ALERT_1`.

Taux globaux d'alertes :

Alerte	Nombre de lignes	Pourcentage
ALERT_1	4908	1,56 %
ALERT_2	10739	3.41 %
ALERT_3	27385	8.7 %

Perspectives

- Poursuite des extractions ;
- Diminution des fausses alertes ;
- Effectuer une extraction OCR sur les fichiers critiques avec Qwen 3.6

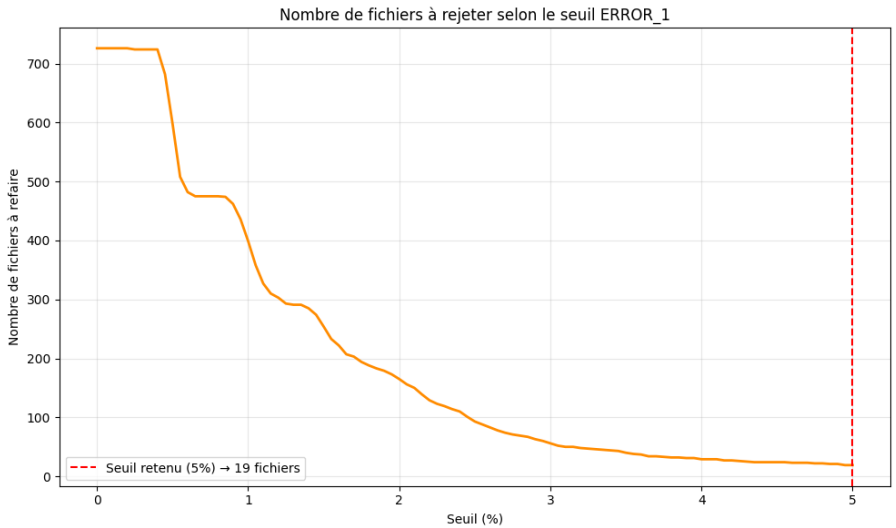


Figure: Variation du nombre de fichiers à reprendre selon le seuil : 1873-1888

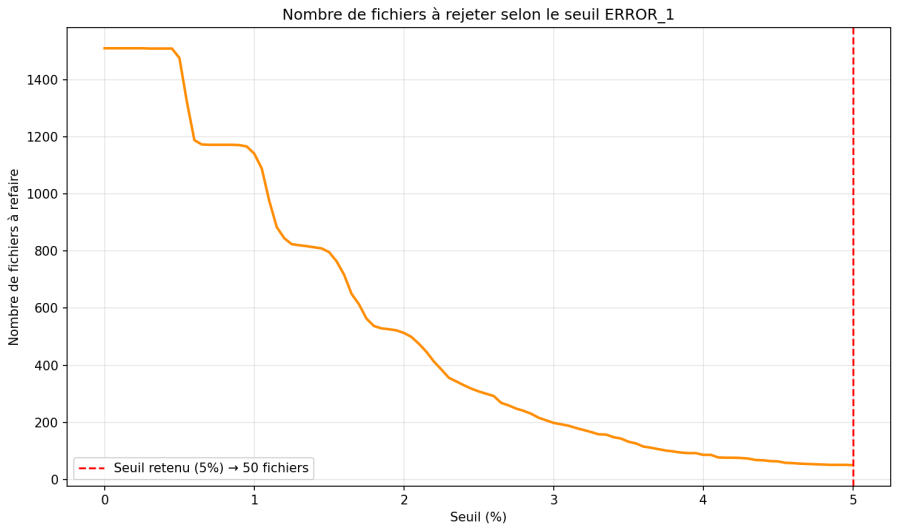


Figure: Variation du nombre de fichier à reprendre selon le seuil : 1890-1900

Merci pour votre attention

Questions ?