Université de Rouen Normandie

UFR Sciences et Techniques

Extraction dinformation dans les annuaires de la ville de Strasbourg (1873-1953)

Auteur : Fortuné Wladimir TOSSA

Formation : Master 1 Sciences des Données : Apprentissage Automatique pour l'Intelligence Artificielle

Année universitaire : 2025–2026

Encadrant : M. Thierry PAQUET

Rapport de stage

11 Mai au 13 Juillet 2026

Table des matières

1 Introduction **2**

2 Contexte et présentation **2**
2.1 Projet POP-STRAS 2
2.2 Présentation des données 2
2.3 Irrégularité des données 4

3 Expériences et résultats **5**
3.1 Présentation des modèles utilisés 5
3.1.1 Mistral Large 3 5
3.1.2 Qwen 3.6 6
3.2 Métriques d'évaluation 7
3.3 Expériences 9
3.3.1 Mistral Large 3 9
3.3.2 Qwen3.6 13
3.3.3 Conclusion 17

4 Validation des données et Production **18**
4.1 Validation des données 18
4.1.1 Alerte ALERT_1 18
4.1.2 Alerte ALERT_2 19
4.1.3 Alerte ALERT_3 21
4.1.4 Alerte ENTRP 22
4.2 Production 23

5 Conclusion **24**

6 Perspectives **25**

1 Introduction

2 Contexte et présentation

2.1 Projet POP-STRAS

Le projet POP-STRAS, financé par l'ANR (Agence Nationale de la Recherche), à pour objectif de constituer une base de données des individus et des familles ayant résidé dans la ville de Strasbourg au cours de la période 1873-1953, sur la base de lanalyse du fichier domiciliaire constitué de fiches par familles renseignées à la main par les agents de la ville. Pour améliorer le processus de reconnaissance automatique des écritures manuscrites, le projet compte croiser les informations reconnues avec celles disponibles dans les annuaires imprimés de la ville.

L'objectif de ce stage est donc de concevoir et de développer un processus d'extraction des informations contenues dans ces annuaires imprimés (NOM, PRÉNOM, PROFESSION, ADRESSE ...), basé sur l'utilisation des LLM (Large Language Model).

2.2 Présentation des données

Nous disposons de 50 années d'annuaires scannés par double page de 1873 à 1953. Chaque annuaire est constituée de deux (2) types d'entrées, contenant les mêmes personnes mais divergeant sur la façon de les présenter : **les entrées par nom et les entrées par rue**. Dans un premier temps, nous nous concentrerons dans un sur les entrées par nom car les images ont été préalablement transformées en fichier TXT par un processus OCR (Optical Character Recognition), comme illustré sur l'exemple de la figure 2. Cela nous permettra de d'élaborer un processus fonctionnel sans attendre d'extraire toutes les données.

Chaque année contient environ une centaine de fichiers contenant les entrées par nom. Chaque fichier contient les entrées d'une image, c'est-à-dire 4 colonnes d'entrées de personnes. Environ deux cents (200) entrées de personnes par fichiers (voir 1).

Au total nous disposons d'environ un million d'entrée par nom à extraire sous format CSV comme illustré sur la figure 3. Les informations à extraire de ces lignes sont les suivantes :

- **NOM** : le nom de famille de la personne ;
- **PRÉNOM** : le/les prénom(s) de la personne ;
- **PROFESSION** : la profession de la personne ;
- **COMPLÉMENT DE PROFESSION** : toute précision sur la profession de la personne ;

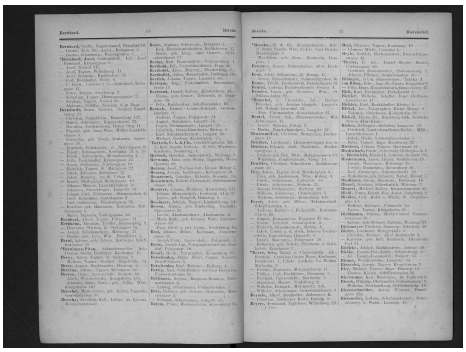
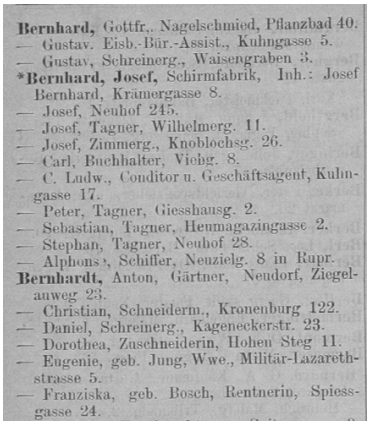


Figure 1: Une double page d'entrée par nom de l'annuaire 1884



Bernhard, Gottfr., Nagelschmied, Pflanzbad 40.
— Gustav. Eisb.-Bür.-Assist., Kuhngasse 5.
— Gustav, Schreinerg., Waisengraben 3.
***Bernhard, Josef,** Schirmfabrik, Inh.: Josef Bernhard, Krämergasse 8.
— Josef, Neuhof 245.
— Josef, Tagner, Wilhelmerg. 11.
— Josef, Zimmerg., Knoblochsg. 26.
— Carl, Buchhalter, Viebg. 8.
— C. Ludw., Conditor u. Geschäftsagent, Kuhngasse 17.
— Peter, Tagner, Giesshausg. 2.
— Sebastian, Tagner, Heumagazingasse 2.
— Stephan, Tagner, Neuhof 28.
— Alphons, Schiffer, Neuzielg. 8 in Rupr.
Bernhardt, Anton, Gärtner, Neudorf, Ziegelauweg 23.
— Christian, Schneiderm., Kronenburg 122.
— Daniel, Schreinerg., Kageneckerstr. 23.
— Dorothea, Zuschneiderin, Hohen Steg 11.
— Eugenie, geb. Jung, Wwe., Militär-Lazarethstrasse 5.
— Franziska, geb. Bosch, Rentnerin, Spiessgasse 24.

(a) Sous partie d'une image d'un annuaire

```
<column>
Bernhard, Gottfr,. Nagelschmied, Pflanzbad 40.
— Gustav. Eisb.-Bür.-Assist., Kuhngasse 5.
— Gustav, Schreinerg., Waisengraben 3.
*Bernhard, Josef, Schirmfabrik, Inh.: Josef
Bernhard, Krämergasse 8.
— Josef, Neuhof 245.
— Josef, Tagner, Wilhelmerg. 11.
— Josef, Zimmerg., Knoblochsg. 26.
— Carl, Buchhalter, Viebg. 8. -— C. Ludw., Conditor u. Geschäftsagent, Kuhn gasse
17.
— Peter, Tagner, Giesshausg. 2.
— Sebastian, Tagner, Heumagazingasse 2.
— Stephan, Tagner, Neuhof 28. ■— Alphonse, Schiffer, Neuzielg. 8 in Rupr.
Bernhardt, Anton, Gärtner, Neudorf, Ziegel auweg 23.
— Christian, Schneiderm., Kronenburg 122.
— Daniel, Schreinerg., Kageneckerstr. 23.
— Dorothea, Zuschneiderin, Hohen Steg 11.
— Eugenie, geb. Jung, Wwe., Militär-Lazarethstrasse 5.
— Franziska, geb. Bosch, Rentnerin, Spiess gasse 24.
```

(b) Extraction OCR correspondante

Figure 2: Un exemple du résultat du processus dOCRisation (à droite) depuis l'image de gauche.

- **NOM DE VOIE** : nom de voie ou habite la personne ;
- **NUMÉRO DE VOIE** : numéro de voie où habite la personne ;
- **FAUBOURG** : faubourg où habite la personne, différent de la voie ;
- **PROPRIÉTAIRE** : signale si la personne est propriétaire de son domicile ou pas ;
- **NOM DE JEUNE FILLE** : nom de jeune de la personne si cette dernière est une femme ;
- **SITUATION** : signale si la personne est veuve ou célibataire ;
- **ADRESSE PROFESSIONNELLE** : adresse du lei de travail ou de la boutique de la personne.

En dehors du nom, toutes ces informations peuvent ne pas être mentionnées. Dans ces cas, leurs valeurs sont mises à *****, sauf le champ PROFESSION qui prend la valeur **Sans** en cas d'absence.

Figure 3: Extrait de la sortie CSV attendue

```
NOM,PRENOM,PROFESSION,COMPLEMENT_DE_PROFESSION,NOM_DE_VOIE,NUMERO_DE_VOIE,
    FAUBOURG,PROPRIETAIRE,NOM_DE_JEUNE_FILLE,SITUATION,ADRESSE_PROFESSIONNELLE
Bernhard,Gottfr.,Nagelschmied,*,Pflanzbad,40,*,*,*,*,*
Bernhard,Gustav,Eisb.-Bür.-Assist.,*,Kuhngasse,5,*,*,*,*,*
Bernhard,Gustav,Schreinerg.,*,Waisengraben,3,*,*,*,*,*
Bernhard,Josef,Kaufm.,"Bernhard Josef Schirmfabrik Inh.",Krämergasse,8,*,*,*,*,*
Bernhard,Josef,Sans,*,*,245,Neuhof,*,*,*,*
Bernhardt,Eugenie,Sans,*,Militär-Lazarethstrasse,5,*,*,Jung,Ww.,*
Bernhardt,Franziska,Rentnerin,*,Spiessgasse,24,*,*,Bosch,*,*
```

2.3 Irrégularité des données

L'un des obstacles dans l'extraction des données est la structure interne des entrées. En effet, comme le montre la figure 1 :

- l'ordre des champs n'est pas toujours le même d'une ligne à une autre ;
- une information absente n'est pas signalée, sa place est simplement prise par un autre champ ;
- l'utilisation des tirets pour éviter la répétition des noms. En effet si la l'entrée suivante porte le même NOM que l'entrée précédente, le NOM est remplacé par '' ;
- certaines entrées s'étendent sur deux (2) lignes, rendant impossible le fait de considérer une entrée par ligne ;
- la présence des entrées d'entreprises à partir de 1882. Ces entrées concernent une entreprise et précise toutes les personnes y travaillant avec leurs informations plus ou moins complètes ;
- utilisation irrégulière des virgules et des points.

De plus comme indiqué sur la figure 2, l'extraction OCR a introduit certaines erreurs dans le texte obtenu. En effet :

- certaines entrées sont mal extraites ;
- le retour à la ligne n'est pas toujours respecté entre les entrées ;

3 Expériences et résultats

3.1 Présentation des modèles utilisés

3.1.1 Mistral Large 3

De sa version exacte `mistral-large-2512`, Mistral Large 3 [1] est un LLM développé par Mistral AI, publiée en décembre 2025. Il s'agit d'un modèle multimodal polyvalent de pointe, à poids variables, doté d'une architecture granulaire de type «Mixture-of-Experts ». Il compte 41 milliards de paramètres actifs et 675 milliards de paramètres au total.

Les points forts de Mistral sont les suivants :

- **Une grande capacité de token d'entrée** : jusqu'à **128.000** tokens en entrée, permettant au modèle de prendre en charge de très grands contextes ;
- **Une architecture MoE granulaire** [2] : en effet, Mistral est constitué de sous-réseaux experts spécialisés. Lorsqu'il traite une requête, il active uniquement les expert nécessaire, constituant les 41 milliards de paramètres actifs ; tous les experts inutiles restent désactivées, parmi les 675 milliards de paramètres inactifs. Ce mécanisme garantie une excellente précision dans les résultats, avec un temps d'inférence court et une consommation d'énergie linéaire.

La figure suivante montre des résultats de plusieurs tests de performance, comparant Mistral Large 3 à DeepSeek3.1 et Kimi-K2 :

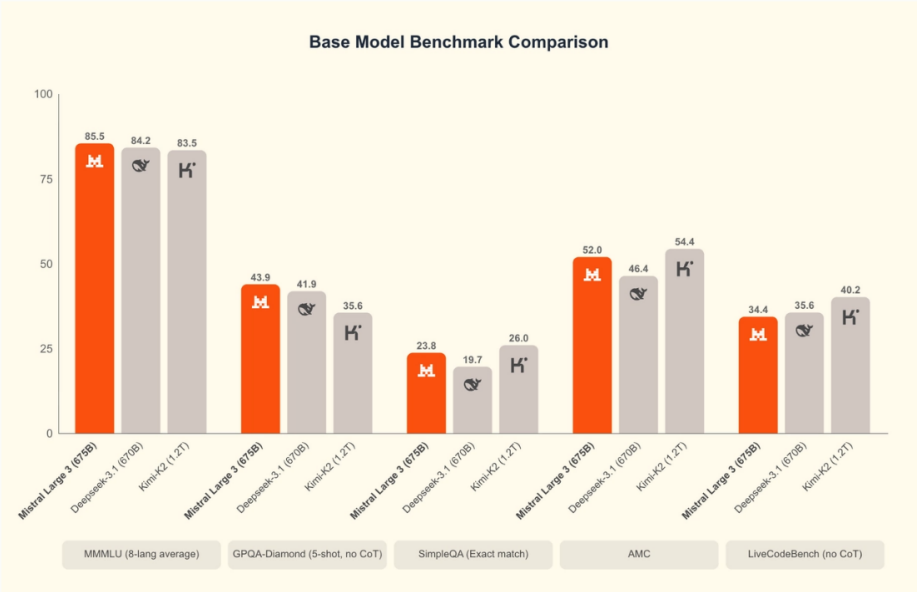


Figure 3: Comparaison de Mistral Large 3 à d'autres modèles

Pour l'extraction de nos données, nous avons utilisé le SDK python fourni par le module `mistralai`[3] de Mistral AI avec un forfait gratuit.

3.1.2 Qwen 3.6

De sa version exacte `Qwen3.6-35B-A3B`, Qwen3.6 est un LLM développé par Alibaba Cloud et publié en Avril 2026. Il s'agit d'un modèle «mixture-of-experts »(MoE) allégé mais remarquablement performant, comptant 35 milliards de paramètres au total et seulement 3 milliards de paramètres actifs [4].

Le principal point fort de Qwen 3.6 est son nombre de paramètres relativement petit, qui ne l'empêche pas de dépasser d'autres modèles relativement équivalents en nombres de paramètres. Il dispose également d'un routeur interne lui permettant de sélectionner des **sous-réseaux experts** qui sont activés pour l'inférence sur une tâche particulière, formant les 3 milliards de paramètres actifs ; tous les autres restes inactifs parmi les 35 milliards de paramètres au total.

La figure 4 montre des résultats de plusieurs tests de performance, comparant Qwen 3.6 à d'autres modèles Qwen plus ancien mais aussi au modèle Gemma de Google.

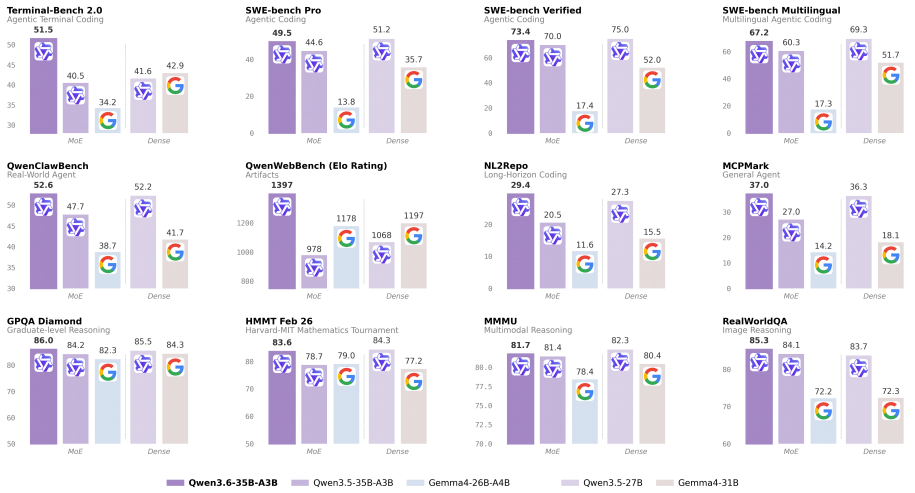


Figure 4: Comparaison de Qwen 3.6 à d'autres modèles

Pour l'extraction de nos données, le modèle a été installé en local sur un serveur H100 du LITIS avec ... de vRAM. Les requêtes sont faites par appels API.

3.2 Métriques d'évaluation

Dans le but d'évaluer les performances de notre modèle, nous avons constitué manuellement une ground truth en annotant **509** entrées extraites sur l'étendue des 10 années traitées sur la période 1873 à 1883 afin d'avoir des données de test représentatives.

Les performances des modèles ont ensuite été évaluées avec une combinaison de deux(2) métriques : la **CER** et le **score F1**

La CER (Character Error Rate) est une métrique permettant d'évaluer la reconnaissance d'écriture, manuscrite ou imprimée. Il mesure le pourcentage de caractères qui diffèrent entre une transcription automatique et une référence vérifiée.
Il est calculé en mesurant la distance d'édition entre la transcription automatique et la vérité de terrain (Ground Truth), normalisée par la longueur du texte de référence.

$$CER = \frac{S + I + D}{N}$$

Où :

S est le nombre de substitutions.

I est le nombre d'insertions.

D est le nombre de suppressions (*deletions*).

N est le nombre total de caractères dans la référence.

Le score F1 est une métrique qui combine la **précision** et le **rappel**, qui permettent respectivement d'évaluer, parmi toutes les prédictions positives du modèle, combien se sont avérées exactes, et combien ont été classées correctement par le modèle parmi tous les vrais positifs.
Le score F1 permet donc de pénaliser les modèles qui obtiennent de bons résultats sur l'un mais pas sur l'autre.

$$Precision = \frac{TP}{TP + FP}$$
$$Recall = \frac{TP}{TP + FN}$$
$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Ainsi pour l'évaluation des performances, nous calculons d'abord un score de CER ; si le score est supérieur à une certaine valeur seuil, la valeur est considérée comme bien prédite et reçoit un score de **1**. Sinon un score de **0** lui est attribué. Dans un second temps, nous calculons le score F1 sur les prédictions ainsi obtenues.
Nous avons évalué les modèles non seulement sur la qualité globale de l'extraction, mais aussi sur la qualité de l'extraction par champ, afin de déterminer quelle information est la plus problématique à extraire.
Le tableau suivant résume l'ensemble des métriques utilisées :

Métrique	**Niveau**	**Description**	**Seuils**
F1 + CER	Par champ	Taux d'erreur caractère sur les TP	0%, 10%, 30%
F1 + CER	PROF_COMBINED	CER sur la concaténation PROFESSION + COMPLÉMENT	0%, 10%, 30%
F1 + CER	Global	Taux d'erreur caractère sur l'ensemble des informations extraites	0%, 30%
F1 binaire	Par champ	Détection présence/absence de chaque champ	–

Table 1: Métriques d'évaluation

Les champs PROFESSION et COMPLEMENT DE PROFESSION seront combinés lors de l'évaluation parce que le modèle pourrait séparer les informations concernant la profession d'une manière différente de la référence, sans pour autant ne perdre aucune information.

3.3 Expériences

Le prompt 7 et les exemples utilisés ont été enrichis au fil des expériences en fonction des erreurs rencontrées dans les extractions. Nous avons construit un prompt structuré avec des règles précises pour chaque champ à extraire. En plus du prompt, le contenu d'un fichier exemple a été concaténé à la suite du prompt. Le fichier exemple est constitué de deux(2) parties : d'abord une partie ENTRÉE TXT avec 38 lignes de données ; une seconde partie SORTIE CSV constituée des 38 lignes au format CSV correspondantes aux lignes en entrées. Le prompt et les exemples sont mis en annexe du document.

Les LLM disposent d'un processus de réflexion (think_process) qui détaille les décisions prises pour produire les résultats qui est inclus dans la réponse produite à une requête. Il est aussi possible d'imposer un format de sortie des résultats. Les expériences menées consistent à tester ces différentes options avec chacun des modèles et à relever les performances obtenues.

Le tableau **??** est un résumé des expériences à effectuer avec Mistral et Qwen.

Table 2: Résumé des expériences réalisées

Expérience	**Modèle**	**Réponse formatée JSON**	**<think>**
E1	Mistral	Non	Oui
E2	Mistral	Oui	Non
E3	Qwen	Non	Non
E4	Qwen	Non	Oui
E5	Qwen	Oui	Non

3.3.1 Mistral Large 3

Les modèles Large de Mistral n'ont pas d'option pour exclure le bloc de réflexion de la réponse. Nous testerons donc uniquement l'influence du format de sortie.

E1 : Sans format & Avec <think>
Dans cette expérience, nous réalisons une extraction d'informations sans forcer le format de sortie.
Voici les résultats obtenus :

Modèle	**CER = 0%**	**CER $\leq$ 30%**
Mistral Large 3	0.955	0.963
Temps / fichier	$\sim$2 min	

Table 3: CER global et temps de traitement par fichier (E1)

Champ	F1 binaire	CER = 0%	CER ≤ 10%	CER ≤ 30%
NOM	1.000	0.997	0.997	0.999
PRENOM	0.999	0.997	0.997	0.998
NOM DE VOIE	0.992	0.973	0.982	0.985
NUMERO DE VOIE	1.000	0.984	0.984	0.984
FAUBOURG	0.795	0.967	0.967	0.967
PROPRIETAIRE	0.778	0.800	0.800	0.800
NOM DE JEUNE FILLE	0.959	1.000	1.000	1.000
SITUATION	0.810	0.520	0.520	0.520
ADRESSE PROFESSIONNELLE	0.688	0.533	0.533	0.625
PROF_COMBINED	0.997	0.980	0.981	0.987

Table 4: F1 binaire et CER par champ (E1)

Les résultats obtenus ne montrent que de faibles performances d'extraction sur la majorité des champs. Cela s'explique en majorité par les hallucinations du modèle qui ajoute des champs vides aléatoires ou des virgules supplémentaires ou omises dans les extractions. Cela décale les autres valeurs extraites les rendant ainsi fausses ou absentes.
Prenons l'exemple de cette ligne :

`Baury Renatus, Schlossermeister, Ballbausg.  17, Tel.  393, Wohn.: Schweighäuscrstr.  18`

Attendu : `...,*,*,*,*,Ballbausg.  17`

Produit : `...,*,*,*,*Ballbausg.  17,ADD`

La sortie est correcte jusqu'au champ SITUATION, mais la virgule a été omise, ce qui rend le champ SITUATION faux et le champ ADRESSE PROFESSIONNELLE vide. La valeur 'ADD' à la fin indique que des virgules supplémentaires ont été ajoutées à la fin de la ligne mais ont été supprimés lors du traitement des réponses.

De manière générale, on remarque que :

- les champs NOM, PRENOM et NUMERO DE VOIE sont toujours extraits en général. Par contre la qualité des informations extraites, dans le cas du NOM et du PRENOM, baisse légèrement. Cette baisse est essentiellement dû à la présence des titres *'von', 'de', 'senior', 'junior'* etc qui sont parfois ignorés. Concernant la qualité des numéro de voie extraits, elle ne varie pas avec le seuil du CER. Cette baisse se justifie par des décalages dues à des champs omis ou ajoutés ;
- le champ FAUBOURG et PROPRIETAIRE sont mal détectés et leurs qualités est aussi affectée par les décalages dans les champs ;
- le champ NOM DE JEUNE FILLE est assez bien détecté et la valeur

est toujours correcte. Les anomalies dans la détection proviennent des exemples ou la valeur n'est pas présente dans la référence, donc vide dans l'extraction mais que les décalages dans les champs ont corrompus ;

- les champs SITUATION et ADRESSE PROFESSIONNELLE sont à la fois mal détectés et leur qualité est encore plus basse. Cela est dû au fait que ces valeurs sont les dernières à extraire. Elles sont donc plus affectées et corrompues par les hallucinations du modèle ;
- les champs PROFESSION et COMPLEMENT DE PROFESSION combinés en PROF_COMBINED sont bien extraits mais la qualité de la donnée extraite baisse ; cela est dû au fait que pour certains champs vides le modèle attribut la valeur **'*'** au lieu de la valeur **'Sans'** attendue. De plus, lorsque qu'une personne est *Rentnerin* (retraîtée), le modèle lui attribue une valeur 'Sans'.

E2 : Avec format & Sans <think>
Au cours de cette expérience, nous réalisons une extraction des informations en précisant un format de sorti en JSON. Le processus de réflexion est automatiquement exclu de la réponse. Le format utilisé est disponible dans l'annexe. Voici les résultats obtenus :

Modèle	**CER = 0%**	**CER ≤ 30%**
Mistral Large 3	0.980	0.990
Temps / fichier	∼7 min	

Table 5: CER global et temps de traitement par fichier (E2)

Champ	**F1 binaire**	**CER = 0%**	**CER ≤ 10%**	**CER ≤ 30%**
NOM	1.000	0.999	0.999	1.000
PRENOM	0.999	0.998	0.998	0.999
NOM DE VOIE	0.997	0.976	0.987	0.994
NUMERO DE VOIE	1.000	0.995	0.995	0.995
FAUBOURG	0.954	1.000	1.000	1.000
PROPRIETAIRE	1.000	1.000	1.000	1.000
NOM DE JEUNE FILLE	1.000	1.000	1.000	1.000
SITUATION	0.973	0.912	0.912	0.912
ADRESSE PROFESSIONNELLE	0.952	0.706	0.706	0.778
PROF_COMBINED	1.000	0.988	0.990	0.996

Table 6: F1 binaire et CER par champ

Les résultats obtenus montrent une net amélioration de la détection et de la qualité d'extraction sur l'ensemble des champs. Cela s'explique par le fait que :

- la précision du format de sortie réduit fortement les risques d'hallucination et de valeurs manquées par le modèle ;

- le modèle s'assure que chaque valeur extraite corresponde à la clé du champ correspondant et respecte les règles définies dans le prompt.

En dépit de ces améliorations, la précision du format de sortie conduit à un temps d'inférence **3.5 fois plus long** et une plus grande consommation de tokens en raison des clés répétées dans les réponses. Il faut noter en plus qu'une fois le format de sortie spécifié, le processus de réflexion est automatiquement exclu de la réponse.

L'analyse détaillée des résultats montre :

- un très bon taux de détection global sur l'ensemble des champs ;
- quelques erreurs dans la qualité des NOM. Cela est dû aux titres qui sont manqués parfois. Le score parfait avec une CER à 30% le prouve bien ;
- le NOM DE VOIE est assez bien détecté mais n'est pas toujours de bonne qualité. Cela s'explique par le fait que l'adresse professionnelle est souvent confondue avec le domicile, et que les hallucinations du modèle conduisent à ce que certains noms de voie abrégés en 'str.' ou 'gr.' se retrouvent développés dans la réponse en 'strasse' ou 'grosse'. Cette dernière raison se justifie par la hausse de performance en F1 quand on augmente le seuil de CER ;
- le NUMERO DE VOIE étant une valeur numérique a priori, est toujours bien détecté mais pas toujours de bonne qualité. En effet certains numéros de voie comportent des indications comme '12 a', et sont donc plutôt alphanumériques ; le modèle ignore la seconde partie du numéro, malgré les précisions dans le prompt. De plus, le modèle confond parfois les adresses professionnelles et les domiciles, ce qui implique que les numéros associés soient aussi confondus ;
- le champ FAUBOURG est mal détecté en raison des confusions fréquentes avec le NOM DE VOIE. Par contre les valeurs extraites sont toujours correctes ;
- la performance relativement basse sur le champ SITUATION s'explique par le fait qu'il n'y a que **37** exemples avec ce champ à extraire, ce qui pénalise fortement les erreurs. Les erreurs produites sont dues à une omission et une confusion entre un prénom 'W.' et la valeur 'Ww.' attendue ;
- l' ADRESSE PROFESSIONNELLE est en générale toujours extraite mais est très souvent confondue avec le domicile ;
- les champs combinés PROFESSION et COMPLEMENT DE PROFESSION sont toujours extraits, avec une meilleure qualité.

Conclusion
Les expériences menées avec Mistral ont montré l'influence du format de sortie sur les performances du modèle. Les performances obtenues en précisant un format de sortie JSON sont nettement meilleures mais consomment beaucoup plus de tokens et prennent plus de temps d'inférence.
La majorité des champs sont bien extraits sauf ceux concernant les adresses qui ont des structures et des sens fortement similaires.
Ces performances nous servirons de baseline pour les expériences à mener avec Qwen3.6.

3.3.2 Qwen3.6

Contrairement aux modèles Large de Mistral, Qwen3.6 dispose d'une option `enable_thinking`[5] à préciser dans la requête pour autoriser ou non le processus de réflexion.
Les expériences à réaliser sont les suivantes :

- sans format + sans tkink_process ;
- sans format + avec think_process ;
- avec format JSON + avec think_process.

Comme avec Mistral, préciser le format de sorti exclu automatiquement le processus de réflexion de la réponse.

E3 : Sans format & Sans <think>
Au cours de cette expérience, le format de la réponse n'est pas contraint et le processus de réflexion est exclu de la réponse du LLM.
Voici les résultats obtenus :

Modèle	**CER = 0%**	**CER $\leq$ 30%**
Qwen 3.6	0.955	0.963
Temps / fichier	$\sim$1 min 20 s	

Table 7: CER global et temps de traitement par fichier (E3)

Champ	F1 binaire	CER = 0%	CER ≤ 10%	CER ≤ 30%
NOM	1.000	0.996	0.996	0.997
PRENOM	0.998	0.997	0.997	0.998
NOM DE VOIE	0.998	0.987	0.995	0.997
NUMERO DE VOIE	0.999	0.998	0.998	0.998
FAUBOURG	0.967	0.949	0.967	0.967
PROPRIETAIRE	1.000	1.000	1.000	1.000
NOM DE JEUNE FILLE	0.989	0.989	0.989	0.989
SITUATION	0.960	0.103	0.103	0.103
ADRESSE PROFESSIONNELLE	0.750	0.778	0.778	0.842
PROF_COMBINED	0.998	0.980	0.983	0.993

Table 8: F1 binaire et CER par champ (E3)

L'analyse détaillée des résultats obtenus montrent :

- un bon niveau global de détection des champs ;
- uniquement deux (2) erreurs de formatage dans la génération de la réponse finale ;
- la mauvaise qualité des prédictions sur les champs SITUATION et ADRESSE PROFESSIONNELLE n'est donc pas due aux hallucinations, mais plutôt aux limites du modèle à prédire correctement ces champs ;
- la SITUATION est très prédite mais sa valeur ne correspond pas à celle attendue '**Ww.** ;
- l'ADRESSE PROFESSIONNELLE est souvent confondu avec le numéro de voie et la seule erreur de formatage se trouve sur ce champ ;
- le champ FAUBOURG est assez bien détecté mais la qualité de l'extraction baisse légèrement. En effet les faubourgs sont confondus avec les adresses ;
- le champ NOM est bien détecté mais quelques erreurs de qualité subsistent dans les prédictions en raison du mauvais rendu des titres et de la mauvaise gestion des tirets ;
- les erreurs sur le champ NOM DE JEUNE FILLE sont dus aux valeurs corrompus par les hallucinations du modèle ;
- les champs combinés de profession sont assez bien détectés. La baisse de qualité s'explique par la suppression de certains éléments jugés inutiles par le modèle.

E4 : Sans format & Avec <think>
Au cours de cette expérience, le format de la réponse n'est pas contraint et le processus de réflexion est inclus dans la réponse.
Les résultats obtenus sont les suivants :

Modèle	**CER = 0%**	**CER ≤ 30%**
Qwen 3.6	0.982	0.986
Temps / fichier	∼5 min	

Table 9: CER global et temps de traitement par fichier (E4)

Champ	**F1 binaire**	**CER = 0%**	**CER ≤ 10%**	**CER ≤ 30%**
NOM	1.000	0.993	0.993	0.993
PRENOM	0.998	0.998	0.998	0.998
NOM DE VOIE	0.999	0.990	0.994	0.996
NUMERO DE VOIE	0.999	0.997	0.997	0.997
FAUBOURG	0.984	0.984	0.984	0.984
PROPRIETAIRE	1.000	1.000	1.000	1.000
NOM DE JEUNE FILLE	1.000	1.000	1.000	1.000
SITUATION	1.000	1.000	1.000	1.000
ADRESSE PROFESSIONNELLE	0.900	0.900	0.900	0.900
PROF_COMBINED	0.999	0.990	0.991	0.996

Table 10: F1 binaire et CER par champ (E4)

Les résultats obtenus après cette expérience montrent :

- une nette amélioration des performances par rapport à E, confirmant l'hypothèse selon laquelle le LLM se corrige automatiquement durant le processus de réflexion ;
- une meilleure performance de Qwen que Mistral dans les mêmes conditions ;
- un temps d'exécution très long, bien que toujours plus rapide que Mistral dans les mêmes conditions.

Une analyse détaillée de ces résultats montrent :

- une absence totale d'hallucinations. En effet aucun champ n'a été corrompu lors de la génération finale après le processus de réflexion ;
- un très bon niveau global de détection et de qualité des champs extraits ;
- les performances sur le champs FAUBOURG restent inchangés au niveau qualitatif. En effet, seule une valeur n'a pas été détectée, tous les autres sont correctes ;
- la baisse de qualité sur le champ NOM est due à la suppression des titres (von) précédents les noms ;
- de manière globale, la majorité des champs sont bien détectés mais avec certains caractères corrigés par le LLM (espaces supprimés, virgule conservés, points retirés), qui les rendent différents de la vérités terrains.

E5 : Avec format & Sans <think>
Au cours de cette expérience, le format de la réponse n'est pas contraint et le processus de réflexion est automatiquement exclu dans la réponse.
Les résultats obtenus sont les suivants :

Modèle	**CER = 0%**	**CER ≤ 30%**
Qwen 3.6	0.982	0.985
Temps / fichier	∼1 min 30 s	

Table 11: CER global et temps de traitement par fichier (E5)

Champ	**F1 binaire**	**CER = 0%**	**CER ≤ 10%**	**CER ≤ 30%**
NOM	1.000	1.000	1.000	1.000
PRENOM	0.999	0.999	0.999	1.000
NOM DE VOIE	0.994	0.988	0.992	0.994
NUMERO DE VOIE	0.999	0.999	0.999	0.999
FAUBOURG	0.909	0.984	0.984	0.984
PROPRIETAIRE	1.000	1.000	1.000	1.000
NOM DE JEUNE FILLE	1.000	1.000	1.000	1.000
SITUATION	0.987	1.000	1.000	1.000
ADRESSE PROFESSIONNELLE	0.952	0.952	0.952	0.952
PROF_COMBINED	1.000	0.988	0.990	0.994

Table 12: F1 binaire et CER par champ (E5)

Les résultats obtenus à l'issue de cette expérience montrent :

- des performances globales similaires à celle de E4 ;
- un temps d'exécution **3x** plus rapide que E4 ;
- des performances strictes légèrement supérieures à celle de E2 avec Mistral.

Une analyse détaillée de ces résultats montrent :

- Des extractions parfaites sur les champs NOM, PRENOM, PROPRIÉTAIRE et NOM DE JEUNE FILLE, confirmant l'amélioration de la qualité avec le formatage de la sortie ;
- les performances relativement basses sur les champs NOM DE VOIE et FAUBOURG sont dues au fait que certaines VOIE sont considérées comme des FAUBOURG en raison de l'absence des suffixes "strasse" ou "gasse" ;
- l'ADRESSE PROFESSIONNELLE est manquée une fois, ce qui justifie les mêmes performances en détection et en qualité. Ce champ est assez fortement pénalisé car il n'est pas assez représenté dans le test ;

- le champ SITUATION est manqué également une fois. En effet sur l'entrée `Brunneau geb. Tortroteau Friderique W., Gastwirthin, Schlutfeld 9.`, le prénom 'W.', a été considéré, en considérant le contexte, par le LLM comme une abréviation de la mention de veuve 'Wittwe'. Nous l'avions considérer dans la vérité terrain comme une abréviation d'un deuxième prénom.

Conclusion
Les expériences menées avec Qwen 3.6 nous permettent d'en arriver aux conclusions suivantes :

- Sans processus de réflexion, le modèle exploite peu les règles fournies et modifie beaucoup plus les valeurs attendues ;
- Qwen 3.6 est meilleur que Mistral sur cette tâche en dépit de sa petite taille. En effet, les performances de Qwen dépassent toujours celles de Mistral dans les mêmes conditions ;
- Le processus de réflexion est aussi performant que le formatage de réponse, pour assurer des extractions de bonne qualité.

3.3.3 Conclusion

Champ	Mistral Large		Qwen 3.6		
	E1 - format + think	**E2** + format - think	**E3** - format - think	**E4** - format + think	**E5** + format - think
NOM	0.997	0.999	0.996	0.993	1.000
PRENOM	0.997	0.998	0.997	0.998	0.999
NOM DE VOIE	0.973	0.976	0.987	0.990	0.988
NUMERO DE VOIE	0.984	0.995	0.998	0.997	0.999
FAUBOURG	0.967	1.000	0.949	0.984	0.984
PROPRIETAIRE	0.800	1.000	1.000	1.000	1.000
NOM DE JEUNE FILLE	1.000	1.000	0.989	1.000	1.000
SITUATION	0.520	0.912	0.103	1.000	1.000
ADRESSE PROFESSIONNELLE	0.533	0.706	0.778	0.900	0.952
PROF_COMBINED	0.980	0.988	0.980	0.990	0.988
Temps / fichier	$\sim$ 2 min	$\sim$ 7 min	$\sim$ 1 min 20 s	$\sim$ 5 min	$\sim$ 1 min 30 s

Table 13: Tableau récapitulatif des expériences réalisées avec CER à 0%

Le tableau précédent est un résumé de toutes les expériences réalisées avec Mistral et Qwen, évaluées avec une CER à 0%. Au termes de ces expériences, nous pouvons conclure que :

- En dépit de sa petite taille, Qwen3.6 performe mieux que Mistral Large dans les mêmes conditions ;
- Le processus de réflexion permet aux LLM de corriger leurs réponses au vue des règles définies dans le prompt, bien qu'il recquiert beaucoup de temps ;

- La précision du format de sortie compense l'absence du processus de réflexion en terme de qualité de résultats ;
- La capacité de formatage des réponses du LLM est assez rigide. En effet les expériences ont montrées que les valeurs entres guillemets dans le texte brut n'étaient pas "échappés" lors de la génération et arrêtait la génération du JSON ;

Afin de passer en production, nous avons donc choisi le modèle **Qwen 3.6** avec un **format de sortie contraint en JSON** et **sans `think_process`**. Cette configuration offre le meilleur compromis temps/performance, comme le montre le tableau ... .

4 Validation des données et Production

Dans un premier temps, nous avons essayer plusieurs configurations afin de choisir celle qui offrait le meilleur compromis qualité/temps. Une fois cette configuration obtenue, nous pouvons passer à l'extraction de l'ensemble de nos données. A ce moment, il se pose une question primordiale : comment assurer que les données produites seront de bonne qualité ?
Pour répondre à cette question, nous avons mis en place un processus de vérification et de validation des données extraites. La vérification se fait en quatre (4) parties, correspondant à des niveaux d'alertes levées :

- **ALERT_1** : Vérifier le respect de l'ordre alphabétique dans le fichier extrait ;
- **ALERT_2** : Vérifier que toutes les informations attendues de l'entrée texte initiale ont été extraites ;
- **ALERT_3** : Vérifier que chaque valeur attribuée à un certain champ, correspond vraiment à ce champ.
- **ENTRP** : Vérifier si l'entrée correspond à une entreprise ;

4.1 Validation des données

4.1.1 Alerte ALERT_1

Définition et objectif
Dans les annuaires initiaux, tous les noms des entrées sont rangées par ordre alphabétique. Ainsi, si le nom d'une entrée extraite ne respecte pas l'ordre alphabétique, il est considéré comme erroné.
Cette alerte nous permet donc de détecter les erreurs sur les champs NOM dans nos extractions. Si un nom est erroné, le champ TEST_1 de cette entrée prend la valeur **ALERT_1**.

Fonctionnement
Pour la mise en place cette alerte, nous avons essayé deux (2) types d'approches :

- Approche par **Fenêtre glissante** :
  Cette approche considère 3 noms consécutifs extraits, fait une copie de cette liste, l'ordonne, puis la compare à la liste initiale. Si les listes diffèrent, il y a donc au moins un nom erronée. Dans un second temps, on retire chaque élément de la liste afin de trouver celui qui provoque la rupture de l'ordre. Cette ligne est donc marquée par l'alerte. S'il y a plus d'un élément qui provoque la rupture, toute la plage des trois (3) noms est marquée par l'alerte.
  Cette approche marche bien, mais elle comporte une principale limite : la forte hypothèse sur le fait qu'un des noms au moins est correcte. En effet lorsqu'on tombe sur un fichier où au cours de l'extraction, un prénom a été pris pour un nom, et que cela se répète sur 10 lignes, la majorité de ces lignes passeront inaperçues.

- Approche par **Détection de zones** :
  Cette approche aborde le problème différemment ; au lieu d'effectuer une comparaison successive, nous détectons d'abord les **"zones"** alphabétiques des noms dans le fichier. De façon concrète nous recherchons les initiaux dominants dans le fichier, puis les plages où ils s'étendent. Les zones doivent tout de même respecter une règle simple : **pas d'imbrication !** En effet nous ne pouvons pas avoir des A, puis des B et revenir aux A. Après détection des zones, tous les noms dans ces zones qui ne commencent pas par l'initial de leur zone, sont considérés comme erronés.
  Cette approche est beaucoup plus robuste que la précédente car elle utilise une sorte de "vérité" issue du fichier lui-même plutôt que des hypothèses.

Nous avons donc mis en place cette alerte avec l'approche par détection de zones.

Limites
Cette alerte est très efficace pour détecter les erreurs sur le champ NOM, mais échoue face aux entrées d'entreprise. En effet ces entrées mentionnent plusieurs personnes, dont les noms, excepté celui du propriétaire, ne respectent évidemment pas l'ordre alphabétique du fichier. Ainsi plusieurs fausses alertes sont levées dans ces cas.

4.1.2 Alerte ALERT_2

Définition et objectif
Lors de l'extraction des données à partir du texte brut, aucune information n'est ajoutée à l'exception du NOM. C'est en quelque sorte une reformulation de l'information initiale sous forme structurée. De plus, le format CSV peut être considéré comme du texte structuré. De ce fait, si une entrée est bien extraite,

le texte initiale et le CSV doivent être similaires.
Partant de ce principe, une **ALERT_2** est levée sur toute extraction CSV qui n'atteint pas un seuil de similarité avec le texte initial de l'entrée.

Fonctionnement
Pour effectuer ce niveau de vérification, les deux (2) chaînes de caractères sont d'abord normalisées (retrait de ponctuations, de caractères spéciaux et des clés), puis sont comparées avec trois (3) mesures de similarités :

- **La similarité de Jaccard** [6]
  La similarité de Jaccard est une mesure statistique utilisée pour quantifier le degré de similarité entre deux ensembles. Elle correspond au rapport entre la taille de l'intersection et celle de l'union. La valeur de la similarité de Jaccard varie entre zéro et un, zéro indiquant que les ensembles n'ont aucun élément en commun et un indiquant qu'ils sont identiques.
  Dans le cas de deux (2) chaînes de caractères, les éléments considérés sont les mots.
  Cette métrique nous permet donc de voir si on retrouve tous les mots du texte dans l'extraction CSV. L'inconvénient de cette métrique est qu'elle est trop stricte. En effet, un seule caractère corrigé par le LLM rend un mot faux et pénalise fortement la métrique.

- **Fuzzy matching**
  Il s'agit d'une approche qui consiste à comparer les deux (2) chaînes de caractères en utilisant des motifs approximatifs plutôt qu'une correspondante stricte comme avec la similarité de Jaccard. Il existe plusieurs façon de d'implémenter ce genre de métrique mais nous avons utilisé le module **RapidFuzz**[7] qui fournit la méthode `token_sort_ratio`. L'avantage de cette méthode c'est qu'il ne tient pas compte de l'ordre des token dans la comparaison.
  Cette métrique nous permet donc de comparée de façon plus souple le texte et le CSV, en étant robuste à l'ordre et aux fautes syntaxiques. La limite de cette métrique est qu'elle peut se révéler trop permissive sur certaines erreurs plus subtiles.

- **Distance de Levenshtein pondérée**
  Elle est égale au nombre minimal d'opérations nécessaires pour transformer une chaîne de caractères en une autre, à l'aide des trois opérations autorisées : remplacement, suppression et ajout.
  Dans la métrique originale, toutes les opérations ont le même coût de 1. Mais dans notre cas, la perte d'information est beaucoup plus critique que l'ajout d'information. De plus le nom sera toujours ajouté par le LLM dans la majorité des cas.
  Ainsi, nous avons défini de nouveaux poids pour nos opérations (du csv vers le texte) :

  – Ajoût (ajoût de l'information au CSV pour retrouver le texte) : **1**

- Suppression (supprimer de l'information du CSV pour retrouver le texte) : **0.2**
- Substitution (remplacer une information) : **0.5**

Le module **weighted-levenshtein**[7] nous a permis de calculer la métrique avec nos poids définis.

Ces trois (3) métriques ont ensuite été testées individuellement pour trouver leurs seuils à chacun, puis ont été combinés dans des conditions imbriquées. Ensuite nous pouvons détecter les différences entre les deux (2) chaînes et en fonction des éléments manquants, on peut lever 3 types d'alertes:

- **ALERT_2 (MISS & ADD)** : éléments manquants des deux(2) côtés ;
- **ALERT_2 (MISS)** : éléments manquants dans le CSV extrait ;
- **ALERT_2 (ADD)** : éléments supplémentaires dans le CSV extrait, en plus du NOM.

En plus de l'alerte, le texte initial est ajouté dans la colonne TEXTE sur la ligne correspondante.

Limites
Cette approche marche très bien pour détecter les éléments supplémentaires et manquants lors de l'extraction.
Notre méthode d'évaluation rencontre cependant une limite face aux entrées d'entreprise. En effet toute les personnes de l'entrée texte sont extraites, de manière à ce qu'une entrée d'entreprise produise plusieurs extractions de personnes, mais le texte utilisé reste toujours le même texte initial global. De ce fait aucune extraction n'est similaire au texte initial, levant ainsi plusieurs fausses alertes.

4.1.3 Alerte ALERT_3

Définition et objectif Ce niveau de vérification permet de s'assurer que les valeurs extraites correspondent aux champs qui leur a été attribué. Il permet donc de détecter les confusions dans les données extraites.
Ainsi si une valeur ne correspond pas au champ qui lui a été attribué, l'alerte ALERT_3 est levée et la valeur correspondante ainsi qu'un score de confiance sont ajoutés dans les colonnes de la ligne.

Fonctionnement Afin d'effectuer cette vérification, nous avons procéder en 2 étapes.

- **Utilisation de dictionnaire de valeurs vérifiées** :
  Ces dictionnaires sont crées sur tous les champs à partir de certains fichiers qui ont été vérifiés manuellement. Ainsi, on vérifie dans un premier si la valeur à classer est présente dans le dictionnaire. Si oui, la valeur est considérée comme valide ; sinon, elle passe à la seconde étape ;
- **Utilisation de classifieurs par rejet** :
  A ce niveau nous avons entraîné des SVM (Support Vector Machine) à classification binaire, sur l'ensemble des valeurs du dictionnaire, en mode Un-Contre-Tous, selon le champ à vérifier. Ainsi si le classifieur ne prédit pas le champ correspondant ou si le score de confiance est en dessous de **50 %**, l'ALERT_3 est levée sur cette ligne.

Ainsi nous pouvons vérifier la validité des valeurs extraites sur les champs PRENOM, PROFESSION, COMPLÉMENT DE PROFESSION, NOM DE JEUNE FILLE, NOM DE VOIE et ADRESSE PROFESSIONNELLE.
En ce qui concerne les champs FAUBOURG, SITUATION et PROPRIÉTAIRE, les valeurs attendues sont limitées ; nous vérifions simplement si la valeur extraites fait partie de la liste.
Pour le champ NUMÉRO DE VOIE, nous vérifions qu'un numéro est bien présent dans la valeur extraite.

Cette alerte ajoute 12 colonnes supplémentaires afin de mentionner les détails possibles sur l'alerte.

Limites
La principale limite de notre méthode d'évaluation se trouve au niveau des classifieurs. En effet, dans les annuaires, à l'exception des noms, toutes les autres valeurs peuvent être abrégés, ce qui les rend difficiles à distinguer. De plus la majorité des noms de voie font référence à des corps de métier ; lorsque ces valeurs sont abrégés, la distinction est quasiment impossible à faire par les classifieurs. De plus un même mot peut avoir un grand nombre d'abréviation, ce qui fait qu'une bonne partie de ces abréviations sont absentes des dictionnaires. De ce fait, un grand nombre de fausses alertes sont levées lors de la validation.

4.1.4 Alerte ENTRP

Définition et objectif
Ce niveau d'évaluation a été créé afin de détecter les lignes d'entreprises et de palier aux fausses alertes sur les alertes 1 et 2.
Ainsi si l'alerte ENTRP est levée sur une ligne, celle-ci ne subit plus les vérifications des niveaux 1 et 2. Par contre, le texte initial est ajouté dans la colonne TEXTE afin que l'opérateur puisse contrôler la validité des données.

Fonctionnement
Pour ce niveau de vérification nous avons de nouveau entraîné un SVM bi-

naire sur les lignes de nos années vérifiées. Dans l'annuaire, toutes les entrées d'entreprise commencent par **'*'**. Mais ce caractère est souvent perdu ou remplacé après le passage de l'OCR, d'où la nécessité d'utiliser un modèle de machine learning pour détecter ces entrées.
Cette vérification se fait avant toute les autres, afin d'éviter les tests 1 et 2 sur les lignes où l'alerte ENTRP a été levée.

4.2 Production

Pour la production en masse des extractions, nous avons mis en place un pipeline qui s'occupe à la fois de l'extraction et de la validation des données. Mais pour la partie concernant la validation des extractions, un problème se posait. Le texte initial est trop bruité et la majorité des sauts de lignes sont manqués ; la structure "une entrée par ligne" est clairement perdue. **Comment effectuer le test de similarité au niveau 2 si nous ne disposons pas du texte utilisé pour l'extraction ?**
Pour répondre à ce problème, nous avons demander au LLM de préciser dans sa réponse, la portion du texte initiale utilisé pour la production de l'extraction retournée. Le format de la réponse a également été modifié avec l'ajout du champ `used_text`.

Une fois ce problème réglé et le processus de validation opérationnel à tous les niveaux, nous avons mis en place un pipeline d'extraction en boucle, contenant trois (3) modules :

- **Extraction TXT-CSV avec le LLM** : un premier module qui se charge de faire passer les fichiers textes par le LLM, récupère les réponses, les mets sous format CSV et les enregistrent dans un dossier intermédiaire et dans la file pour la validation ;
- **Validation des extractions** : ce second module s'active dès qu'un fichier est ajouté à la file de validation. Le fichier contenant les textes des extractions du fichier courant sont aussi récupérés et la validation est effectuée. Si un fichier contient moins de 5% d' ALERT_1 par rapport à son nombre d'entrées le fichier produit contenant les alertes et leurs détails est stocké de manière définitive dans un autre dossier ; sinon l'image correspondant à ce fichier est récupérée et ajoutée dans la file pour le troisième module ;
- **Reprise de l'OCR avec Qwen** : un fichier envoyé au module 3 contient beaucoup trop d'erreurs sur le NOM. On en déduit que le texte utilisé par le LLM pour l'extraction contenait beaucoup trop de bruit et qu'il est donc nécessaire de refaire l'OCR avec Qwen3.6 qui produit des extractions de meilleure qualité.
  Ainsi le module s'active dès qu'une image est ajoutée à la file. Le texte de l'image est produit et le fichier texte initial est remplacé par le nouveau dans le dossier de base. Le fichier est ensuite replacé dans la file du module 1.

Chacun de ces modules est géré par un thread différent, permettant un fonctionnement en parallèle.
La production a été lancée et la durée de traitement est estimée à **250 heures** soit **10 jours et demi**.

5 Conclusion

L'objectif de ce stage au sein du laboratoire LITIS, était de réaliser l'extraction d'une base de données à partir des annuaires de la ville de Strasbourg de 1873 à 1939.

Pour cela, nous avons décider de réaliser l'extraction des données à partir du LLM Qwen 3.6 installé au LITIS. Après plusieurs expériences, nous avons pu atteindre une performance de **98.2%** de F1 avec une CER à 0% sur 509 entrées de tests.
Nous avons ensuite intégré ce modèle dans une pipeline pour la production des données. Ce pipeline est composé de 3 modules :

- un module d'extraction TXT - CSV ;
- un module de vérification de la validité des extractions en 4 niveaux :
  - ordre alphabétique des extractions ;
  - similarité entre le texte initial et le csv produit ;
  - validité des valeurs extraites et des champs attribués.
- un module d'extraction OCR IMAGE - TEXT : si une extraction contient trop d'erreurs dans l'ordre alphabétique, le texte est considéré comme mal extrait et l'extraction OCR est refaite et le fichier et remis dans la file du premier module.

À partir de cette architecture, nous produisons en plus des extractions, des indicateurs d'attention, sous forme d'alertes ajoutés aux extractions, afin de garantir aux futurs utilisateurs des extractions, les démographes, des données fiables et explicables.

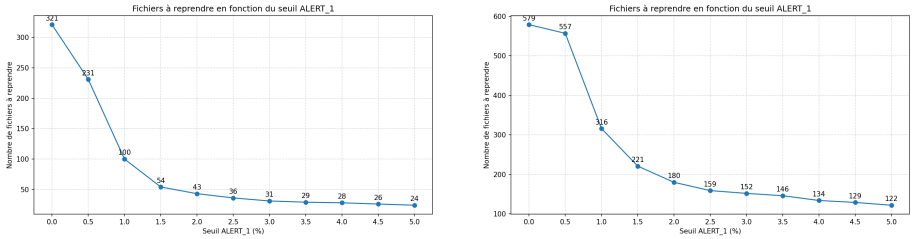
En dépit de ces résultats, nous avons rencontré certaines limites, surtout en raison de la complexité des données, les bruits issus de l'OCR, la présence des entrées d'entreprises, les abréviations, qui face auxquelles le LLM performe assez bien mais où nos processus de vérification atteignent leur limites avec beaucoup de fausses alertes.

Au terme de ce stage, nous avons extrait la totalité des années allemandes de 1973 à 1914, et 1920 qui est une année française. Ces données seront envoyées

aux démographes, avec qui nous avons validés la structure des extractions tout au long du projet, afin qu'il nous donne leur avis sur ces données.

Ce stage nous aura appris la capacité des LLM à extraire des informations dans des documents, mais aussi leurs limites et les approches afin d'obtenir des meilleurs résultats. Nous avons aussi expérimenté l'efficacité de système plus léger et plus simples comme des dictionnaires de valeurs ou des algorithmes de Machine Learning pour valider la qualité des données produites.

6 Perspectives



(a) Évolution des fichiers à retraiter (Période 1873–1888)

(b) Évolution des fichiers à retraiter (Période 1890–1900)

Figure 5: Évolution du volume de fichiers à soumettre à un nouvel OCR selon le seuil d'erreurs toléré.

Les courbes présentées dans la figure 5 modélisent le volume de fichiers qui devront faire l'objet d'un retraitement automatique par OCR, en fonction du seuil d'erreurs que nous choisissons de tolérer. L'analyse de ces résultats s'avère cruciale : elle permet d'identifier graphiquement le point de bascule optimal pour la validation de nos extractions, offrant ainsi un compromis rigoureux entre le temps humain requis pour la correction des OCR et le niveau de fiabilité des données finales. On observe d'ailleurs que les données suivent une distribution parfaitement homogène sur les vingt premières années de notre corpus, s'étendant de 1873 à 1910.

Cette stabilité méthodologique se confronte toutefois à une rupture historique et linguistique lors de la transition vers les données françaises. Pour la validation de la période précédente (les années "allemandes"), l'équipe avait constitué des dictionnaires de valeurs de référence à partir des extractions préalablement validées un processus particulièrement chronophage. Par définition, ces lexiques spécifiques ne sont pas adaptés au traitement des structures syntaxiques et des termes français.

Dès lors, pour éviter de générer des données à l'aveugle et sans garantie de

certitude, nous avons choisi d'isoler et d'extraire uniquement la première année de cette nouvelle transition, à savoir 1920. Ces premiers fichiers tests vont être soumis à l'expertise des démographes. Ce sont leurs retours qui permettront de confirmer si notre architecture technique actuelle demeure robuste ou si elle nécessite des ajustements face à ces données inédites. Une fois cette phase de validation franchie, la production de l'ensemble des extractions pourra être lancée à grande échelle.

Annexe

Listing 4: Schéma JSON imposé aux modèles

```
OUTPUT_FORMAT = {
    "name": "person_list",
    "schema": {
        "type": "object",
        "properties": {
            "result": {
                "type": "array",
                "items": {
                    "type": "object",
                    "properties": {

                        "data": {
                            "type": "object",
                            "properties": {
                                "NOM": { "type": "string" },
                                "PRENOM": { "type": "string" },
                                "PROFESSION": { "type": "string" },
                                "COMPLEMENT DE PROFESSION": { "type": "string" },
                                "NOM DE VOIE": { "type": "string" },
                                "NUMERO DE VOIE": { "type": "string" },
                                "FAUBOURG": { "type": "string" },
                                "PROPRIETAIRE": { "type": "string" },
                                "NOM DE JEUNE FILLE": { "type": "string" },
                                "SITUATION": { "type": "string" },
                                "ADRESSE PROFESSIONNELLE": { "type": "string" }
                            },
                            "required": [
                            "NOM",
                            "PRENOM",
                            "PROFESSION",
                            "COMPLEMENT DE PROFESSION",
                            "NOM DE VOIE",
                            "NUMERO DE VOIE",
                            "FAUBOURG",
                            "PROPRIETAIRE",
                            "NOM DE JEUNE FILLE",
                            "SITUATION",
                            "ADRESSE PROFESSIONNELLE"
                            ]
                        },
                        "used_text": {
                            "type": "string"
                        }
                    },
                    "required": [
                    "used_text",
                    "data"
                    ]
                }
            }
        },
        "required": [
        "result"
        ]
    }
}
```

Listing 5: Schéma JSON imposé pour l'OCR avec Qwen

```
OUTPUT_FORMAT = {
    "name": "person_list",
    "schema":
    {
        'type':'object',
        'properties':{
            'result':{
                "type": "array",
                "items":
                {
                    "type": "string",
                },
            },
        },
        'required': ['result']
    }
}
```

Listing 6: Prompt utilisé pour l'OCR avec Qwen

```
"Extrais toutes les lignes de manière fidèle. "
"CONSERVER OBLIGATOIREMENT et ABSOLUMENT VERBATIM le tiret en
 début de ligne"
"Certaines entrées s'étendent sur 2 lignes, si une entrée ne
commence pas par un nom, associe la à l'entrée précédente
dans une seule ligne"
"retire toutes les lignes qui correspondent à des titres de
section"
"retour à la ligne après chaque ligne"
"pas de numéro de page"
"chaque entrée complète sur une seule ligne"
"NE PAS IGNORER LES TIRETS '' NI LES '*' en début de ligne"
"Ignorer la page qui ne concerne pas les entrées de noms et
toutes les entêtes"
```

Listing 7: Prompt utilisé pour l'extraction des informations des annuaires

```
PROMPT = """
Tu es un extracteur de données, spécialisé dans les annuaires allemands
Voici un annuaire allemand. Extraire EXACTEMENT toutes les champs suivants sous format CSV : NOM,PRENOM,PROFESSION,COMPLEMENT DE
       PROFESSION,NOM DE VOIE,NUMERO DE VOIE,FAUBOURG,PROPRIETAIRE,NOM DE JEUNE FILLE,SITUATION,ADRESSE PROFESSIONNELLE

champ NOM:
- lorsque la ligne débute par un tiret, caractère '-' ou '', le NOM est celui de la ligne précédente.
- 2 entrées sur la même ligne ont le même NOM si le nom de la seconde entrée n'est pas précisé ;
- parfois précédé ou suivi de titre 'von', 'de', 'v.', 'Vater', 'senior', 'junior', 'freiherr', 'frhr.', 'freih.', à déplacer à
       la fin du champ NOM
PRENOM:
- il s'agit du prénom de la personne
- peut être absent
- sans virgule
- '*' si absent
PROFESSION:
- mettre à 'Sans' si absent
- Ne pas confondre avec le champ SITUATION ;
- conserver les valeurs 'Tagner','Tagnerin','Rentnerin','Rentner'.
COMPLEMENT DE PROFESSION
- contient toute précision sur la profession différente de l'adresse professionnelle
NOM DE VOIE:
- adresse réelle en Allemagne
- il est uniquement constitué de mots, qui peuvent être séparés par des caractères '-' ou '' ;
- la valeur du champ peut être préfixée par 'a.' ou 'n.' ; ces préfixes doivent être ajoutés au champ;
- ne pas confondre avec le FAUBOURG
- ne doit pas être ignorer
- parfois précisé avec les clés Wohnung ou Wohn.
NUMERO DE VOIE:
- il est alphanumérique;
- copier VERBATIM
FAUBOURG
- Faubourg dans lequel se trouve la personne
- valeurs possibles : Neudorf, Neuhof, Ruprechtsau, Grüneberg, Königshofen, Kronenburg, Königsh., Rupr., Neuhof
- ne pas confondre avec le NOM DE VOIE
- uniquement les valeurs possibles
NOM DE JEUNE FILLE:
- il apparait après la clé 'geb.' ou 'g.' ou 'gb.'.
- Si la clé est absente la valeur est '*'
SITUATION:
- indique si veuve ou célibataire
- le champ est mis EXACTEMENT à la valeur 'Ww.' UNIQUEMENT si la clé 'Wittve' ou 'Ww.' ou 'Wtw.' ou 'Wwe' apparait ou ledig.
PROPRIETAIRE:
- Les valeurs possibles sont: E., I., II., III. IV., V., D., H.
ADRESSE PROFESSIONNELLE:
- adresse réelle en Allemagne
- adresse du travail de la personne, boutique ou magazin
- précisée avec les clés Geschäft ou Geshäftslokal ou Laden ou ldn.
- elle est présente lorsque la clé 'laden' ou 'ldn' apparaît ou elle est précisée entre parenthèses dans le champ PROFESSION ou
       après le champ VOIE ou le champ NUMERO DE VOIE.
- peut être précisé comme adresse dans le champ PROFESSION  avec 'in der'
REMARQUES GENERALES
- garder le NUMÉRO DE VOIE si le NOM DE VOIE est absent
- garder le NUMÉRO DE VOIE si le FAUBOURG est présent
- certaines entrées s'étendent sur 2 lignes
- 2 entrées sur la même ligne ont le même NOM si le nom de la seconde entrée n'est pas précisé ;
- ne pas confondre FAUBOURG et NOM DE VOIE
- ne pas ignorer le NUMÉRO DE VOIE si NOM DE VOIE est absent
- retirer les virgules à l'intérieur des champs
- chaque valeur de champ doit correspondre au sens défini dans les règles
- extraire OBLIGATOIREMENT le FAUBOURG si présent
- ne pas ignorer le NUMÉRO DE VOIE en présence du FAUBOURG
- les valeurs de chaque champ doivent correspondre à la définition du champ donnée ci-dessus ;
- si le champ PROFRESSION est absent, sa valeur est 'Sans' ;
- si le premier champ d'une ligne ne correspond pas à un nom, alors il faut concaténer cette ligne avec la ligne précédente pour
       formuler une seule entrée à extraire.
- les valeurs doivent être recopiées VERBATIM sans corrections ou développement
- si un champ est absent, sa valeur est mise à '*', sauf le champ PROFESSION qui est mis à 'Sans'
- Neuhof n'est pas un NOM DE VOIE mais un FAUBOURG
- Rupr. est un FAUBOURG
- ne pas garder les clés d'extraction dans les valeurs finales
- ne pas confondre SITUATION ET PROFESSION
- ne jamais ignorer le NUMÉRO DE VOIE
- 'Wittve' ou 'Ww.' ou 'Wtw.' ou 'Wwe' ne sont pas des valeurs de PROFESSION
LIGNES ENTREPRISE
- commence par '*' et représente une entrée d'entreprise.
- le premier champ le nom de l'entrepise. Il doit être ajouté au champ COMPLÉMENT PROFESSIONNEL
- le champ suivant mentionne le ser=cteur d'activité de l'entreprise et est ajouté à COMPLÉMENT PROFESSIONNEL
- la clé Inh ou Inhaber précise les informations du gérant.
- si le gérant n'est pas précisé, le premier champ est dans l'ordre PRENOM NOM
- si l'entrée contient plusieurs personnes, créer une ligne pour chacune d'elles et garder le nom de l'entreprise en COMPLÉMENT D
       'ADRESSE
- la fonction de chaque personne de l'entreprise doit être précisée dans COMPLÉMENT D'ADRESSE
- 'Wittve' ou 'Ww.' ou 'Wtw.' ou 'Wwe' ne sont pas des professions
Voici un exemple complet contenant des lignes et les sorties CSV attendues auquel tu dois te référer \n:

"""
```

Références

[1] Mistral AI. *Mistral Large 3 | Mistral AI docs*. 2025. URL: https://docs.mistral.ai/models/model-cards/mistral-large-3-25-12 (visited on 06/09/2026).

[2] My Social. *Mistral Large 3: How 41B Active Parameters Deliver 675B Intelligence*. 2025. URL: https://medium.com/aimonks/mistral-large-3-how-41b-active-parameters-deliver-675b-intelligence-451aa9230cab (visited on 06/09/2026).

[3] Mistral AI. *Mistral Python Client*. 2026. URL: https://pypi.org/project/mistralai/ (visited on 06/09/2026).

[4] QwenTeam. *Qwen3.6-35B-A3B: Agentic Coding Power, Now Open to All*. 2026. URL: https://qwen.ai/blog?id=qwen3.6-35b-a3b (visited on 06/09/2026).

[5] QwenTeam. *Qwen Deep thinking*. 2026. URL: https://modelstudio.console.alibabacloud.com/ap-southeast-1/?tab=doc#/doc/?type=model&url=2870973 (visited on 06/11/2026).

[6] Joshua Noble. *What is Jaccard Similarity? | IBM*. 2026. URL: https://www.ibm.com/think/topics/jaccard-similarity (visited on 07/09/2026).

[7] Rapidfuzz. *Home - rapidfuzz*. 2026. URL: https://rapidfuzz.com/ (visited on 07/09/2026).